

## SÉANCE DE T.P. N°3

### Cours : Optimisation Optimisation sous contraintes

*L'objectif de cette séance de travaux pratiques est de vous apprendre à coder des algorithmes généraux de minimisation avec contraintes : l'algorithme d'Uzawa et la méthode de pénalisation. L'algorithme d'Uzawa est rappelé au début du TP.*

## Partie I : Quelques rappels de cours

### 1 L'algorithme du gradient projeté

La méthode du gradient projeté s'inspire des méthodes usuelles de gradient. Supposons, d'une façon générale, que l'on souhaite minimiser une fonctionnelle  $J : \mathbb{R}^n \rightarrow \mathbb{R}$  sur un ensemble de contraintes  $C$ . Si l'on construit une suite d'itérés de la forme  $x^{k+1} = x^k + \rho_k d^k$ , où  $d^k$  est une direction de descente, on ne peut pas être sûr que si  $x^k$  appartient à  $C$ , alors  $x^{k+1}$  appartiendra encore à  $C$ . Il faut donc « ramener »  $x^{k+1}$  dans  $C$ , ce que l'on fait en utilisant une projection.

#### ALGORITHME DU GRADIENT PROJETÉ

1. *Initialisation.*

$k = 0$  : on choisit  $x^0 \in \mathbb{R}^n$  et  $\rho_0 \in \mathbb{R}_+^*$ .

2. *Itération  $k$ .*

$$x^{k+1} = \Pi_C \left( x^k - \rho_k \nabla J(x^k) \right).$$

$\Pi_C$  désigne ici la projection sur  $C$

Notons également le résultat de convergence :

**Théorème 1** *On suppose que  $J$  est  $\mathcal{C}^1$ , de dérivée Lipschitzienne, et elliptique, c'est à dire qu'il existe  $\alpha > 0$  tel que :*

$$\forall (x, y) \in (\mathbb{R}^n)^2, (\nabla J(x) - \nabla J(y), x - y) \geq \alpha \|x - y\|^2.$$

*Si l'on choisit le pas  $\rho_k$  dans un intervalle  $[\beta_1, \beta_2]$  tel que  $0 < \beta_1 < \beta_2 < \frac{2\alpha}{M}$ , où  $\alpha$  est la constante d'ellipticité de  $J$  et  $M$ , la constante de Lipschitz de la dérivée de  $J$ , alors la suite  $(x^n)_{n \geq 0}$  d'itérés par la méthode du gradient projeté converge vers la solution du problème de minimisation.*

### 2 L'algorithme d'Uzawa

Supposons que l'on souhaite résoudre sur  $\mathbb{R}^n$  le problème  $(\mathcal{P}) \min J(x), x \in C$ , où :

$$C = \{x \in \mathbb{R}^n, h(x) = 0, g(x) \leq 0\}, \text{ avec } h = (h_i)_{1 \leq i \leq p} \text{ et } g = (g_j)_{1 \leq j \leq q}.$$

Appelons  $\mathcal{L}$ , la fonction Lagrangienne associée à ce problème. Alors :

$$\forall x \in \mathbb{R}^n, \mathcal{L}(x, \lambda, \mu) = J(x) + (\lambda, h(x))_{\mathbb{R}^p} + (\mu, g(x))_{\mathbb{R}^q}.$$

On voit ici que la fonction Lagrangienne englobe à la fois la fonctionnelle  $J$  et les contraintes  $h$  et  $g$ . Elle représente donc bien le problème  $(\mathcal{P})$ . Avant de poursuivre, souvenons-nous de ce que l'on appelle **point selle**.

**Définition 1** On appelle **point selle** de  $\mathcal{L}$  sur  $\mathbb{R}^n \times \mathbb{R}^p \times (\mathbb{R}_+)^q$ , tout triplet  $(x^*, \lambda, \mu)$  vérifiant l'équation :

$$\mathcal{L}(x^*, \lambda, \mu) \leq \mathcal{L}(x^*, \lambda^*, \mu^*) \leq \mathcal{L}(x, \lambda^*, \mu^*), \quad \forall (x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^p \times (\mathbb{R}_+)^q. \quad (1)$$

Le théorème suivant nous permettra de comprendre *intuitivement* l'algorithme d'Uzawa. Pour une compréhension totale, il faudra s'intéresser au problème dual de  $(\mathcal{P})$ .

**Théorème 2** Supposons  $J$ ,  $g$  et  $h$  convexes, de classe  $\mathcal{C}^1$ .

Alors, le triplet  $(x^*, \lambda^*, \mu^*) \in \mathbb{R}^n \times \mathbb{R}^p \times (\mathbb{R}_+)^q$  est un point selle de  $\mathcal{L}$  si, et seulement si ce triplet vérifie les conditions de Kuhn-Tucker.

Ce théorème nous aide à comprendre que, pour chercher le triplet  $(x^*, \lambda^*, \mu^*) \in \mathbb{R}^n \times \mathbb{R}^p \times (\mathbb{R}_+)^q$  vérifiant les conditions de Kuhn-Tucker, on peut procéder de la façon suivante :

- Pour  $(\lambda^*, \mu^*) \in \mathbb{R}^p \times (\mathbb{R}_+)^q$ , fixés, on peut chercher le minimum sans contrainte (i.e. sur tout l'espace  $\mathbb{R}^n$ ) de la fonction  $x \mapsto \mathcal{L}(x, \lambda^*, \mu^*)$ . Cela traduit le terme de droite de l'équation (1).
- Pour  $x^* \in \mathbb{R}^n$  fixé, on cherche le maximum sur  $\mathbb{R}^p \times (\mathbb{R}_+)^q$  de la fonction  $(\lambda, \mu) \mapsto \mathcal{L}(x^*, \lambda, \mu)$ . C'est ce que traduit le terme de gauche de l'équation (1).

C'est cette idée qu'utilise l'algorithme d'Uzawa :

#### ALGORITHME D'UZAWA

1. *Initialisation.*

$k = 0$  : on choisit  $\lambda^0 \in \mathbb{R}^p$  et  $\mu^0 \in (\mathbb{R}_+)^q$ .

2. *Itération  $k$ .*

$\lambda^k = (\lambda_1^k, \dots, \lambda_p^k) \in \mathbb{R}^p$  et  $\mu^k = (\mu_1^k, \dots, \mu_q^k) \in \mathbb{R}^q$  sont connus.

(a) Calcul de  $x^k \in \mathbb{R}^n$  solution de :

$$(\mathcal{P}_k) \min_{x \in \mathbb{R}^n} \mathcal{L}(x, \lambda^k, \mu^k).$$

(b) Calcul de  $\lambda^{k+1}$  et  $\mu^{k+1}$  par les formules :

$$\begin{aligned} \lambda_i^{k+1} &= \lambda_i^k + \rho h_i(x^k), \quad i \in \{1, \dots, p\} \\ \mu_j^{k+1} &= \max(0, \mu_j^k + \rho g_j(x^k)), \quad j \in \{1, \dots, q\}. \end{aligned}$$

Enfin, signalons le théorème suivant qui pourrait se révéler utile en pratique :

**Théorème 3** On suppose que  $J$  est  $\mathcal{C}^1$  et elliptique. Supposons de plus que  $h$  est affine,  $g$  est convexe de classe  $\mathcal{C}^1$  et lipschitziennes. On suppose de plus que le Lagrangien  $\mathcal{L}$  possède un point

selle  $(x^*, \lambda^*, \mu^*)$  sur  $\mathbb{R}^n \times \mathbb{R}^p \times (\mathbb{R}_+)^q$ . Alors, il existe  $\rho_1$  et  $\rho_2$ , avec  $0 < \rho_1 < \rho_2$  tels que, pour tout  $\rho \in [\rho_1, \rho_2]$ , la suite  $(x^k)_{k \geq 0}$  générée par l'algorithme d'Uzawa converge vers  $x^*$ . De plus, on sait que  $\rho_2 = \frac{\alpha}{2(M_h^2 + M_g^2)}$ , avec  $\alpha$ , la constante d'ellipticité de  $J$ ,  $M_h$  et  $M_g$ , les constantes de Lipschitz associées à  $h$  et  $g$ .

## Partie II : Exercices

### EXERCICE N. 1

#### Optimisation d'un portefeuille d'actions

TPUza1

On considère le problème de l'Optimisation d'un portefeuille. Supposons que l'on possède  $n$  actions, que l'on représente par des variable aléatoires  $R_1, \dots, R_n$ . Chaque action rapporte en moyenne à l'actionnaire  $e_i = \mathbb{E}(R_i)$  (espérance de  $R_i$ ) au bout d'un an. On suppose que l'on investit une somme  $S$  donnée, et l'on note  $x_i \in \mathbb{R}$ , la proportion de la somme investie dans l'action  $i$ . Ainsi, on a :  $\sum_{i=1}^n x_i = 1$ . Le portefeuille total est représenté par la variable aléatoire :

$$R = \sum_{i=1}^n x_i R_i \text{ et rapporte donc en moyenne : } \mathbb{E}(R) = \sum_{i=1}^n x_i e_i.$$

On désire imposer un rendement donné  $r_0 > 0$ , ce qui se traduit par :  $r_0 = \sum_{i=1}^n x_i e_i$ .

On modélise le risque du portefeuille par :  $\sigma^2(x) = \mathbb{E}[(R - \mathbb{E}(R))^2]$ .

On note  $A = (a_{ij})_{\substack{1 \leq i \leq n \\ 1 \leq j \leq n}}$ , la matrice de covariance définie par la relation :

$$\forall (i, j) \in \{1, \dots, n\}^2, a_{ij} = \mathbb{E}[R_i - \mathbb{E}(R_i)][R_j - \mathbb{E}(R_j)].$$

On peut alors écrire que  $\sigma^2(x) = (x, Ax)$ . On appelle  $J$ , la fonctionnelle définie sur  $\mathbb{R}^n$  par :

$$J(x) = \frac{1}{2}(x, Ax).$$

On appelle également  $K$ , l'ensemble des contraintes :  $K := \{x \in \mathbb{R}^n : (x, u) = 1 \text{ et } (x, e) = r_0\}$ . Le but de ce TP est de déterminer numériquement la solution du problème :

$$(\mathcal{P}) \quad \begin{cases} \min J(x) \\ x \in K \end{cases}.$$

1. Mettre l'ensemble des contraintes sous la forme  $K = \{x \in \mathbb{R}^n : Cx = f\}$ , où  $C$  et  $f$  désignent respectivement une matrice et un vecteur à préciser. Rappeler comment se traduisent les conditions d'Optimalité de ce problème et formuler l'équation en  $x$  à résoudre à chaque itération.
2. On souhaite étudier un exemple concret. Supposons que :  $\forall i \in \{1, \dots, n\}, e_i = i$ , que  $r_0 = 2.5$ . Pour les tests numériques, on se placera par exemple dans le cas où  $n = 5$ . Écrire un programme *genere.m* permettant de générer la matrice  $A$  à l'aide des instructions suivantes :

```
A=diag(e./n);
R=rand(n,n);
A=A+0.1.*R'*R;
```

Expliquer la dernière ligne du programme.

3. Pour différentes matrices  $A$ , programmer l'algorithme d'Uzawa. On n'oubliera pas d'imposer un nombre maximal d'itérations.
4. Quel inconvénient majeur constatez-vous ici ?
5. On appelle donc à présent  $\tilde{K}$ , l'ensemble défini par :

$$\tilde{K} = \{x \in \mathbb{R}^n : x \geq 0, (x, u) = 1 \text{ et } (x, e) = r_0\}.$$

Si l'on souhaite améliorer la résolution du problème, on est amené à résoudre :  $\min_{x \in \tilde{K}} J(x)$ .

6. Comment doit-on choisir la constante  $\rho$  qui intervient dans l'algorithme d'Uzawa. Soyez précis.
7. Écrire l'algorithme d'Uzawa écrit sous sa forme la plus générale, puis le tester.

## EXERCICE N. 2

### Mise en œuvre d'une méthode de pénalisation

TPPen

On considère la fonctionnelle  $J$  définie sur  $\mathbb{R}^2$  par :  $J(x, y) = 2x^2 + 3xy + 2y^2$ .

On appelle  $Q$  le cadran défini par :

$$Q = \left\{ x \leq -\frac{1}{2}, y \leq -\frac{1}{2} \right\}$$

1. (a) Quelle est la solution du problème de minimisation de  $J$  sans contrainte ?
- (b) On appelle  $X^*$ , le minimum de  $J$  sous la contrainte  $X^* \in Q$ .  
Démontrer que, nécessairement,  $\nabla J(X^*) = 0$  ou  $X^* \in \partial Q$ .
- (c) Mettre en œuvre la méthode du gradient projeté pour résoudre le problème de minimisation :

$$\min_{(x,y) \in Q} J(x, y).$$

Pensez-vous que la méthode du gradient conjugué peut être associée à la méthode de projection ? Pourquoi ?

- (d) Représenter les itérés par cette méthode.
2. **S'il vous reste du temps.** Nous allons reprendre le même problème que précédemment, et évaluer une méthode de pénalisation. On propose les étapes suivantes :
  - (a) Mettre en place une fonction de pénalisation  $x \mapsto \phi(x)$ , en réfléchissant à l'expression qu'elle aura sur le cadran  $Q$ . Déterminer alors le gradient de la fonctionnelle pénalisée.  
**Remarque :** attention au choix de la pénalisation ! La fonctionnelle pénalisée doit être différentiable.
  - (b) Tracer les courbes de niveau de la nouvelle fonction coût et son gradient, pour plusieurs valeurs de  $\varepsilon$ . Que constatez-vous quant à la vitesse de variation de la fonction coût ? Dans la suite, on tracera le gradient uniquement sur le domaine admissible.
  - (c) Pour une valeur petite de  $\varepsilon$ , par exemple  $\varepsilon = 10^{-4}$  (pénalisation forte), et un point de départ  $x_0 = (-0.3, 0.5)^t$ , tester la méthode de pénalisation pour les méthodes de gradient à pas fixe et à pas optimal. En visualisant les itérés, peut-on dire que la vitesse de convergence est satisfaisante ? Répéter le test pour  $\varepsilon = 0.5$  (pénalisation faible). Que peut-on dire de la convergence ? Quid de la solution trouvée ?
  - (d) Dédire de ces observations une méthode qui converge plus rapidement.